STK1000 – Obligatorisk oppgave 2 (bio)

XXXXXXX-XXXXX

Oppgave 1 – Utvalgsfordelinger (genlengder)


```
# Data
datapath <- "https://www.uio.no/studier/emner/matnat/math/STK1000/data/obligdata/oblig2/gene.txt"
genes <- read.table(datapath, header=TRUE, sep=";")
Gene.Lengths <- genes$Gene.Lengths</pre>
```

1a) Fordeling i populasjonen


```
mu <- mean(Gene.Lengths, na.rm=TRUE) # gjennomsnitt
sigma <- sd(Gene.Lengths, na.rm=TRUE) # standardavvik
cat("1a) mu =", round(mu,2), " sigma =", round(sigma,2), "\n")
1a) mu = 2610.39 sigma = 1817.44

hist(Gene.Lengths, breaks="FD", col=mck_lightblue, border=NA,
    main="1a: Histogram av genlengder", xlab="Genlengde (bp)", ylab="Frekvens")</pre>
```

1a: Histogram av genlengder



1a: QQ-plot




Tolkning 1a: Moderat høyreskjev fordeling; QQ-plot avviker i høyre hale. Normalantakelse er bare delvis rimelig. Nivå/spredning 2610.39 / 1817.44.

1b) Utvalg n = 100


```
set.seed(100)
x100_once <- sample(Gene.Lengths, 100, replace=TRUE)
xbar100_once <- mean(x100_once)</pre>
cat("1b) xbar (ett utvalg, n=100) =", round(xbar100_once,2), "\n")
1b) xbar (ett utvalg, n=100) = 2767.98
# 100 utvalg (n=100) i tråd med hint
meanvec <- rep(NA, 100)</pre>
for(i in 1:100){
  sample.now <- sample(Gene.Lengths, 100, replace=TRUE)</pre>
  meanvec[i] <- mean(sample.now)</pre>
cat("1b) mean(xbar) =", round(mean(meanvec),2),
    " sd(xbar) =", round(sd(meanvec),2),
    " teori sigma/sqrt(100) =", round(sigma/sqrt(100),2), "\n")
1b) mean(xbar) = 2591.2
                          sd(xbar) = 184.03 teori sigma/sqrt(100) = 181.74
hist(meanvec, breaks="FD", col=mck_lightblue, border=NA,
     main="1b: Fordeling av xbar (n=100, B=100)", xlab="xbar", ylab="Frekvens")
```

1b: Fordeling av xbar (n=100, B=100)



qqnorm(meanvec, main="1b: QQ-plot av xbar (n=100)"); qqline(meanvec, col=mck_teal, lwd=2)

1b: QQ-plot av xbar (n=100)




 $\textbf{Tolkning 1b: } \bar{x} \; (n=100) \; er \; smal \; og \; tilnærmet \; normal. \; sd(\bar{x}) \quad \textbf{sigma/sqrt(100)} \; \rightarrow \; stabile \; gjennomsnitt.$

1c) Utvalg n = 10


```
set.seed(101)
meanvec10 <- rep(NA, 100)
for(i in 1:100){</pre>
```

1c: Fordeling av xbar (n=10, B=100)



qqnorm(meanvec10, main="1c: QQ-plot av xbar (n=10)"); qqline(meanvec10, col=mck_teal, lwd=2)

1c: QQ-plot av xbar (n=10)



Tolkning 1c: \bar{x} (n=10) er bredere og mer variabel enn for n=100; $sd(\bar{x})$ større som forventet.

1d) Sannsynlighet $P(\bar{x} > 3000)$

```
p10 <- 1 - pnorm(3000, mean=mu, sd=sigma/sqrt(10))
p100 <- 1 - pnorm(3000, mean=mu, sd=sigma/sqrt(100))
cat("1d) P(xbar > 3000): n=10 = ", signif(p10,3), "\n")
1d) P(xbar > 3000): n=10 = 0.249
cat("1d) P(xbar > 3000): n=100 = ", signif(p100,3), "\n")
1d) P(xbar > 3000): n=100 = 0.016
```

Tolkning 1d: Sannsynligheten blir mye mindre når n øker (\bar{x} tettere rundt).

1e) Bias og varians

Kort: \bar{x} er **ubiasert** for (bias=0). $Var(\bar{x})={}^2/n \rightarrow større n$ gir mer presise anslag.


Oppgave 2 – Signifikanstester og konfidensintervaller (ozon NYC 1973)

```
# Data
datapath2 <- "https://www.uio.no/studier/emner/matnat/math/STK1000/data/obligdata/oblig2/ozone.txt"
newyork <- read.table(datapath2, header=TRUE)
Ozone <- newyork$Ozone
Temp <- newyork$Temp
Month <- newyork$Month
Day <- newyork$Day</pre>
```


2a) Oppsummering + antakelser

```
<- mean(Ozone, na.rm=TRUE)</pre>
median_03 <- median(Ozone, na.rm=TRUE)</pre>
          <- sd(Ozone, na.rm=TRUE)</pre>
sd_03
          <- IQR(Ozone, na.rm=TRUE)</pre>
iqr_03
summary(Ozone)
   Min. 1st Qu. Median
                            Mean 3rd Qu.
   4.00
          18.00
                   30.50
                           40.45
                                    59.50 122.00
hist(Ozone, breaks="FD", col=mck_blue, border=NA,
     main="2a: Histogram av Ozone (ppb)", xlab="Ozone (ppb)", ylab="Frekvens")
```


2a: Histogram av Ozone (ppb)



2a: Boxplot Ozone



2a: QQ-plot Ozone



Tolkning 2a: Høyreskjev fordeling med uteliggere; normalantakelsen er svak.

Antakelser t-prosedyre: uavhengige observasjoner, omtrent normalitet på gjennomsnitt (CLT hjelper), ingen ekstreme avvik som dominerer. t (ikke z) fordi er ukjent.

2b) Test mot 30 ppb + 90 % og 99 % KI

```
# HO: mu = 30, H1: mu > 30 (ensidig)
t greater 90 <- t.test(Ozone, mu=30, alternative="greater", conf.level=0.90)
t_greater_99 <- t.test(Ozone, mu=30, alternative="greater", conf.level=0.99)
t_greater_90
    One Sample t-test
data: Ozone
t = 3.6395, df = 107, p-value = 0.0002112
alternative hypothesis: true mean is greater than 30
90 percent confidence interval:
36.74982
               Inf
sample estimates:
mean of x
  40.4537
t_greater_99
    One Sample t-test
data: Ozone
t = 3.6395, df = 107, p-value = 0.0002112
alternative hypothesis: true mean is greater than 30
99 percent confidence interval:
33.67016
               Inf
sample estimates:
mean of x
  40.4537
cat("2b) ensidig p-verdi =", signif(t_greater_90$p.value,3), "\n")
2b) ensidig p-verdi = 0.000211
cat("2b) 90% KI =", paste(round(t_greater_90$conf.int,1), collapse=" ; "), "\n")
2b) 90\% \text{ KI} = 36.7 \text{ ; Inf}
cat("2b) 99% KI =", paste(round(t_greater_99$conf.int,1), collapse=" ; "), "\n")
2b) 99\% KI = 33.7; Inf
```

Tolkning 2b: Konkluder om >30 ut fra p-verdi. 99 % KI er bredere enn 90 %; sjekk om 30 er utenfor.

2c) Juli/august vs. mai/juni/september

```
# Del etter måned (i tråd med hint)
oz.juli.august <- newyork[newyork$Month %in% c(7,8), "Ozone"]
oz.mai.juni.sept <- newyork[newyork$Month %in% c(5,6,9), "Ozone"]


# Welch to-utvalgs t-test
tt2 <- t.test(oz.juli.august, oz.mai.juni.sept)
tt2

Welch Two Sample t-test

data: oz.juli.august and oz.mai.juni.sept
t = 4.9526, df = 80.631, p-value = 3.957e-06
alternative hypothesis: true difference in means is not equal to 0</pre>
```

```
95 percent confidence interval:
16.06035 37.63270
sample estimates:
mean of x mean of y
55.61702 28.77049
m_JA <- mean(oz.juli.august, na.rm=TRUE)</pre>
m_MJS <- mean(oz.mai.juni.sept, na.rm=TRUE)</pre>
cat("2c) mean(JA) =", round(m_JA,1),
    " mean(MJS) =", round(m_MJS,1),
    " p-verdi =", signif(tt2$p.value,3), "\n")
2c) mean(JA) = 55.6 mean(MJS) = 28.8 p-verdi = 3.96e-06
# --- 2c: figur (boksplot + punkter) ---
par(mfrow = c(1, 2))
boxplot(
  oz.juli.august, oz.mai.juni.sept,
  names = c("JA", "MJS"),
  col = c(mck_teal, mck_lightblue),
  main = "2c: Ozone etter gruppe",
  ylab = "Ozone (ppb)"
stripchart(
 list(JA = oz.juli.august, MJS = oz.mai.juni.sept),
 vertical = TRUE, method = "jitter",
  pch = 16, col = mck_grey, add = TRUE
par(mfrow = c(1, 1))
```

2c: Ozone etter gruppe




Tolkning 2c: Si om forskjellen er signifikant (p<0.05) og hvilken gruppe som er høyest (JA vs. MJS).

Oppgave 3 – Lineær regresjon (katter: Bwt \rightarrow Hwt)


```
if (!requireNamespace("MASS", quietly=TRUE)) install.packages("MASS")
library(MASS)
dat <- MASS::cats
bwt <- dat$Bwt
hwt <- dat$Hwt</pre>
```

3a) Spredningsplott + modell + antagelser

3a: Hjertevekt vs kroppsvekt



```
# Enkel diagnostikk (antagelser)
par(mfrow=c(1,2))
plot(fit, which=1)
plot(fit, which=2)
```



Tolkning 3a: Klar positiv trend; rett linje virker rimelig. Residual-plot uten sterk kurve/heteroskedastisitet og omtrent rett QQ-plot støtter antagelsene greit.


3b) Skjæringspunkt og stigningstall + 95 % KI

Tolkning 3b: Stigningstallet er økningen i forventet hjertevekt (g) ved +1 kg kroppsvekt. Veldig lav p-verdi \rightarrow forkast H0: slope=0 klar lineær sammenheng.

3c) Prediksjons- og konfidensintervall + prediksjon ved 3.0 kg

```
xval <- seq(min(bwt), max(bwt), length.out=200)
newd <- data.frame(bwt = xval)
pi <- predict(fit, newdata=newd, interval="prediction")  # prediksjon (bred)
ci <- predict(fit, newdata=newd, interval="confidence")  # konfidens (smal)</pre>
```

3c: Linje + 95% KI (smal) og 95% PI (bred)



```
pred_3 <- predict(fit, newdata=data.frame(bwt=3.0), interval="prediction")
cat("3c) Predikert hjertevekt ved 3.0 kg = ",
    round(pred_3[1],2), " g, 95% PI = [",
    round(pred_3[2],2), ", ", round(pred_3[3],2), "]\n", sep="")
3c) Predikert hjertevekt ved 3.0 kg = 11.75 g, 95% PI = [8.86, 14.63]</pre>
```

Tolkning 3c: KI gjelder forventet respons (linja). PI gjelder én katt (bredere pga. individvariasjon). Se tall for 3.0 kg over.